

Big data – Aula repositórios dados — Prof Jader Lima

Atividade pyspark – databricks community – repositório de dados

A atividade tem como objetivo a resolução de exercícios sobre datalake/datalakehouse de dados utilizando o framework de processamento distribuído spark, na linguagem pyspark, plataforma databricks, versão community.

Criar pastas no Workspace do databricks community

- Organize seus notebooks, criando diretórios no Workspace do databricks, seguindo os passos abaixo:
- Acesse o menu lateral Workspace
- Botão direito do mouse, Create, Folder, informe o nome do folder e confirme.
- Crie a seguinte estrutura
- - dengue
 - filecopy
 - ingestion
 - transformation
 - reporting

Importar os notebooks de exercícios para o Workspace do databricks, respeitando a estrutura abaixo:

- dengue
 - filecopy
 - **download_dengue_files**
 - ingestion
 - ingestion_chuva
 - ingestion_dengue
 - transformation
 - transformation_chuva
 - transformation_dengue
 - reporting
 - report_dengue

Criar um Cluster no Databricks versão community

- Acesse sua conta do databricks community.
- Acesse o menu lateral **Compute**
- Na página Compute, clique em **Create Compute**.
- Informe um nome para o cluster e confirme a criação no botão **Create Compute**.
- **O cluster será desligado e inutilizado após 1 ou 2 horas sem uso, nesse caso é necessário repetir os passos acima para um novo cluster.**

Exportar os notebooks do databrick para sua máquina local

- Acesse sua conta do databricks community.
- Acesse o menu lateral Workspace
- Botão direito do mouse no notebook, **Export**, **Python Notebook**.
- **O notebook será exportado para a pasta Downloads.**
- **É possível fazer o import utilizando o meu File durante a utilização do notebook**

Big data – Aula repositórios dados — Prof Jader Lima

Passo a passo para a resolução, após importar todos os notebooks do exercício

Camada Transient

Execute o notebook **download_dengue_files**

Verifique os arquivos copiados nos diretórios abaixo

- `"/FileStore/transient/dados_degue/chuvas/"`
- `"/FileStore/transient/dados_degue/casos_dengue/"`

No final do notebook adicione o comando `dbutils` para exibir os arquivos copiados

Camada Bronze

ingestion_dengue

O notebook `ingestion_dengue` está concluído, a título de ajuda, basta executar o notebook.

ingestion_chuva

Faça a implementação do notebook `ingestion_chuva`, utilize o notebook de dengue como exemplo, os dados devem ser salvos utilizando a `MERGE/UPDATE`.

Camada Silver**transformation_dengue**

Faça a leitura dos dados da camada bronze num dataframe spark

Faça as seguintes transformações abaixo

Crie os campos ano, mês, dia

Renomeie os campos conforme abaixo :

- 'codigo_ibge',
- 'data_medicao',
- 'quantidade_casos',
- 'cidade',
- 'estado',
- 'cep'

Apos as transformações, utilize a MERGE/UPDATE para salvar os dados na camada silver

transformation_chuva

Faça a leitura dos dados da camada bronze num dataframe spark

Faça as seguintes transformações abaixo

Crie os campos ano, mês, dia

Renomeie os campos conforme abaixo :

- data_medicao
- mm
- estado
- ano
- mês
- dia

Existem valores inválidos nos dados de chuva, identifique os valores faça um filtro para excluir esses valores – dica, valores inválidos podem ser valores impossíveis, que não fazem sentido na análise.

Apos as transformações, utilize a MERGE/UPDATE para salvar os dados na camada silver

Camada Gold

report_dengue

Faça a leitura dos dados da camada silver num dataframe spark, para os dados de chuva e os dados de dengue.

Crie um banco de dados spark-sql , chamado **dengue_chuvas**

Faça as seguintes análises

analise_chuvas

- quantidade de chuvas agrupado pelo campos , 'ano','mes','estado'
- salve o resultado como uma tabela gerenciada , chamada **analise_chuvas**
- realize uma consulta sql usando a tabela salva

analise_dengue

- quantidade de casos de dengue agrupado pelos campos, 'ano','mes','estado','cidade'
- salve o resultado como uma tabela gerenciada , chamada **analise_dengue**
- realize uma consulta sql usando a tabela salva

analise_chuvas_dengue

A ultima analise, exiba num mesmo dataframe a :

- soma da quantidade de casos de dengue agrupados por 'ano','mes','estado' ,
- média de chuva agrupado por ano','mes','estado' .
- novo campo dividindo a soma dos casos de dengue / media de chuva
- Salve o resultado como uma tabela gerenciada , chamada **analise_chuvas_dengue**
- Realize uma consulta sql usando a tabela salva

Para a ultima analise, fazer a soma de chuvas num dataframe, a média em outro dataframe, fazer a junção dos dataframes resultantes e por ultimo fazer o novo campo com a divisão.

Entrega : Execute após a conclusão dos exercícios propostos, cada linha de exercício deve exibir o resultado com o `display()` ou `show()`.

Para a entrega, exporte os notebooks com os comandos de exibição executados, crie um arquivo zip com a disposição abaixo

- **dengue**
 - **filecopy**
 - **download_dengue_files.ipynb**
 - **ingestion**
 - **ingestion_chuva.ipynb**
 - **ingestion_dengue.ipynb**
 - **transformation**
 - **transformation_chuva.ipynb**
 - **transformation_dengue.ipynb**
 - **reporting**
 - **report_dengue.ipynb**
- **Atenção:** Ao entregar o arquivo, adicione seu nome ao final do arquivo, conforme exemplo abaixo **dengue_RAXXXXXX.zip**