

Big data – Aula pyspark — Prof Jader Lima

Atividade pyspark – databricks community – agregação de dados

A atividade tem como objetivo a resolução de exercícios sobre agregação de dados utilizando o framework de processamento distribuído spark, na linguagem pyspark, plataforma databricks , versão community.

O notebook já contém os comandos necessários para a leitura dos dados necessários para a análise.

O exercício pressupõe que os dados já estejam carregados no FileStore do databricks, caso ocorra algum erro de leitura na dos dados executar novamente o notebook, **download_copy_files**.

Importar o notebook de exercícios para o Workspace do databricks

- Importe notebook **exercicio_agregacao.ipynb** conforme abaixo.
- Acesse sua conta do databricks community.
- Acesse o menu lateral Workspace
- Botão direito do mouse, import .
- Na janela Import Notebooks, clique em browse e selecione o arquivo
- **exercicio_agregacao_dados.ipynb** e confirme a importação.

Criar pastas no Workspace do databricks community

- Caso deseje organizar seus notebooks, pastas podem ser facilmente criadas no Workspace do databricks , seguindo os passos abaixo:
- Acesse o menu lateral Workspace
- Botão direito do mouse, Create, Folder , informe o nome do folder e confirme.

Criar um Cluster no Databricks versão community

- Acesse sua conta do databricks community.
- Acesse o menu lateral **Compute**
- Na página Compute, clique em **Create Compute** .
- Informe um nome para o cluster e confirme a criação no botão **Create Compute**.
- **O cluster será desligado e inutilizado após 1 ou 2 horas sem uso, nesse caso é necessário repetir os passos acima para um novo cluster.**

Exportar o notebook do databrick para sua máquina local

- Acesse sua conta do databricks community.
- Acesse o menu lateral Workspace
- Botão direito do mouse no notebook, **Export , Ipython Notebook**.
- **O notebook será exportado para a pasta Downloads** .
- **É possível fazer o import utilizando o meu File durante a utilização do notebook**

Big data – Aula pyspark — Prof Jader Lima

Entrega : Execute após a conclusão dos exercícios propostos, cada linha de exercício deve exibir o resultado com o `display()` ou `show()`.

- **Atenção:** Ao entregar o notebook, adicione seu nome ao final do arquivo, conforme exemplo abaixo **exercicio_agregacao_dados_jader_lima.ipynb**

Big data – Aula pyspark — Prof Jader Lima

Parametros para configuração dos services (containers) no docker-compose :

container - mongo

imagem

mongo:6-jammy

nome do container

mongo

restart

always

portas

27017:27017

variaveis de ambiente

MONGO_INITDB_PASSWORD – valor da variável **init_pass**

MONGO_INITDB_DATABASE - valor da variável **init_db**

MONGO_INITDB_USERNAME - valor da variável **init_user**

MONGO_INITDB_ROOT_USERNAME - valor da variável **root_user**

MONGO_INITDB_ROOT_PASSWORD - valor da variável **root_pass**

rede

mongo_network

pasta dados container

volume host - **/tmp/mongo-data**

pasta no container - **/data/db**

Big data – Aula pyspark — Prof Jader Lima

container mongo-express

imagem

mongo-express

nome

mongo-express

portas

8081:8081

restart

always

variaveis de ambiente

ME_CONFIG_MONGODB_SERVER - valor da variável **mongo**

ME_CONFIG_BASICAUTH_USERNAME - valor da variável **express_user**

ME_CONFIG_BASICAUTH_PASSWORD - valor da variável **express_pass**

ME_CONFIG_MONGODB_ADMINUSERNAME - valor da variável **root_user**

ME_CONFIG_MONGODB_ADMINPASSWORD - valor da variável **root_pass**

links

mongo